

Руководство по развёртыванию и эксплуатации

1. Назначение

Данное руководство описывает установку, настройку и запуск программного средства анонимизации продуктивной базы данных PostgreSQL. Решение предназначено для использования в CI/CD (GitLab CI) и позволяет получать анонимизированные тестовые дампы из продуктивных данных.

2. Требования к окружению

- **ОС:** Linux (рекомендуется Ubuntu 20.04+, Arch Linux, любой дистрибутив с Docker)
- **Docker** версии 20.10+ и **Docker Compose** (для локального тестирования инфраструктуры)
- **Python** 3.11+ (только для локального запуска вне CI/CD)
- **GitLab** (любая версия с CI/CD) и **GitLab Runner** с доступом к Docker
- **S3-совместимое хранилище** (например, MinIO, AWS S3, Yandex Object Storage)

3. Структура проекта

```
anonymizer/
├── anonymizer/
│   ├── __init__.py
│   ├── config.py           # загрузка YAML-конфигурации
│   └── db.py               # работа с PostgreSQL (восстановление,
дамп, анонимизация)
├── pipeline.py             # основной пайплайн анонимизации
├── s3.py                   # загрузка/выгрузка дампов в S3
└── strategies/             # алгоритмы анонимизации (каждый в
отдельном файле)
    ├── base.py
    ├── registry.py
    └── ... (все стратегии)
├── config/
│   └── anonymization.yaml # конфигурация анонимизации
└── dictionaries/          # текстовые файлы со словарями (имена,
фамилии, слова)
```

```
|— docker-compose.yml      # подъём GitLab, MinIO, PostgreSQL (для
тестирования)
|— .gitlab-ci.yml          # сценарий CI/CD (предоставляется
отдельно)
|— main.py                 # точка входа
|— requirements.txt        # зависимости (psycopg2, boto3, pyyaml,
python-dotenv)
```

4.1. Настройка окружения. Пример используемых(настривались в gitlab variable):

```
MINIO_ROOT_USER=admin
MINIO_ROOT_PASSWORD=tyucvb1620
ENDPOINT_URL=http://minio:9000
POSTGRES_CONTAINER_NAME=""
POSTGRES_USER=admin
POSTGRES_DB=db
POSTGRES_PASSWORD=tyucvb1620
POSTGRES_HOST=postgres
POSTGRES_PORTS=5432:5432
```

4.2. Подготовка словарей

Поместите текстовые файлы со словарями в папку dictionaries/. Каждый файл – одна запись на строку. Пример прикреплён.

В конфигурационном файле anonymization.yaml в секции settings.dictionaries укажите символические имена и пути (относительно корня проекта)

4.3. Настройка конфигурации анонимизации

Файл config/anonymization.yaml (пример прилагается). В нём указываются таблицы, колонки, алгоритмы и параметры. Пример прикреплен.

5. Запуск анонимизации

5.1. Локальный запуск (вне CI/CD)

Установите зависимости: `pip install -r requirements.txt`

Запустите согласно нужным инструкциям. В случае чего используйте `-help`. Для запуска с корня: `python -m anonymizer.main -help`

5.2. Запуск в CI/CD (GitLab)

`.gitlab-ci.yml` прикреплен, зарегистрируйте pipeline.

6. Проверка результата

- После успешного выполнения в целевом S3-бакете появляется файл `anonymized_<timestamp>.sql`.
- Логи анонимизации содержат информацию о каждой обработанной таблице и колонке.
- Анонимизированная база данных сохраняет структуру исходной (индексы, ограничения не копируются, но исходные таблицы не изменяются).

7. Устранение неполадок

Проблема	Возможное решение
Ошибка подключения к S3	Проверьте <code>ENDPOINT_URL</code> , <code>MINIO_ROOT_USER</code> , <code>MINIO_ROOT_PASSWORD</code> , доступность бакетов.
Ошибка восстановления дампа	Убедитесь, что файлы <code>.sql</code> в папке <code>temp/</code> валидны, а контейнер PostgreSQL запущен.
Отсутствует таблица <code>_anonymized</code>	Проверьте конфигурацию: таблица должна быть указана в <code>tables</code> .
Детерминизм нарушен	В <code>BaseAnonymizer</code> используется глобальный кэш, который сбрасывается только при завершении процесса. Для одного запуска детерминизм гарантирован.

8. Добавление новых алгоритмов (кратко)

1. Создать класс-наследник `BaseAnonymizer` в папке `strategies/`.
2. Реализовать метод `_generate(self, value, row)`.

3. Зарегистрировать класс в `__init__.py` через `StrategyRegistry.register('имя', Класс)`.

4. Указать новое имя в `anonymization.yaml` для нужной колонки.

Подробное описание – в документе «Описание архитектуры и порядка добавления новых алгоритмов».